Optimisation de Portefeuille Bayésien : Black-Litterman

Sujet C.5 — Probabilités, ML et Finance Quantitative

Rania Wahbi Louis Jeaate Antoine Serac

ING4 — Finance et Ingénierie Quantitative

ECE Paris

IA Probabiliste, Théorie des Jeux et Machine Learning

Mars 2026

Plan de la présentation

Contexte & Problématique
Markowitz, limites, approche bayésienne

Théorie Black-Litterman
Prior, Views, Posterior, formule BL

Implémentation Python
Architecture, implémentation Python, code source

Résultats & Comparaison
Frontière efficiente, Sharpe, allocations

Analyse de Sensibilité
Confiance aux views, backtesting, robustesse

Synthèse & Conclusion

Objectifs du projet

- ✔ Implémentation BL from scratch
- ✔ Comparaison avec Markowitz
- ✔ Views avec confiances variables
- ✔ Frontière efficiente
- ✔ Backtesting multi-périodes
- ✔ Analyse de sensibilité

Stack technique

Python · NumPy · SciPy
Matplotlib · yfinance · pandas

1. Contexte & Problématique

De Markowitz à Black-Litterman : pourquoi l'approche bayésienne ?

Théorie Moderne du Portefeuille — Markowitz (1952)

Principe fondateur

Harry Markowitz (Prix Nobel 1990) propose de maximiser le rendement espéré pour un niveau de risque donné, en exploitant les **corrélations entre actifs**. C'est la naissance de l'optimisation **Mean-Variance**.

Formulation :

$$\max_{\mathbf{w}} \ \mathbf{w}^\top \boldsymbol{\mu} - \frac{\lambda}{2} \mathbf{w}^\top \boldsymbol{\Sigma} \mathbf{w}$$

sous contrainte $\mathbf{w}^\top \mathbf{1} = 1$, $\mathbf{w} \geq 0$

Points forts

- ✔ Cadre mathématique rigoureux
- ✔ Diversification optimale
- ✔ Frontière efficiente calculable

Limites en pratique

- **Sensibilité extrême** aux estimations de $\boldsymbol{\mu}$ — une erreur de 1 % peut changer radicalement les poids
- **Portefeuilles concentrés** — tendance à sur-allouer quelques actifs
- **Instabilité temporelle** — les allocations fluctuent fortement d'une période à l'autre
- **Estimations naïves** de $\boldsymbol{\mu}$ par la moyenne historique : *garbage in, garbage out*

« The most important problem in asset allocation is estimation error in expected returns. »

— Black & Litterman (1992)

Problématique & Solution Bayésienne

Question centrale

*Comment obtenir une **allocation stable** en combinant l'équilibre de marché avec les **opinions de l'investisseur** de façon probabiliste ?*

Prior

L'équilibre de marché comme point de départ neutre

Rendements implicites aux poids de marché

Views

Opinions de l'investisseur sur des actifs précis

Absolues ou relatives, avec niveau de confiance

Posterior

Combinaison optimale par le théorème de Bayes

Rendements BL plus stables et intuitifs

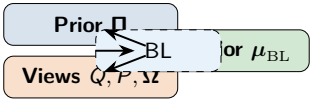

Univers d'actifs — Groupe 03 :

Ticker	Secteur	Cap (Mds$)
AAPL, MSFT	Technologie	2 500 / 2 200
GOOGL, NVDA	Tech / Semi	1 400 / 1 200
AMZN	Consommation	1 100
BRK-B	Diversifié	700
JPM, UNH	Finance / Santé	450 / 450
JNJ, XOM	Santé / Énergie	400 / 440

2. Théorie Black-Litterman

Prior d'équilibre, views, incertitudes, formule posterior

Le Prior d'Équilibre de Marché

Reverse Optimisation

Plutôt que d'estimer $\boldsymbol{\mu}$ par la moyenne historique, on **inverse** l'optimisation : quels rendements impliquent les poids de marché observés ?

$$\boldsymbol{\Pi} = \lambda \boldsymbol{\Sigma} \mathbf{w}_{\mathrm{mkt}}$$

- λ : aversion au risque implicite du marché
- $\boldsymbol{\Sigma}$: matrice de covariance
- $\mathbf{w}_{\mathrm{mkt}}$: poids par capitalisation

Aversion au risque implicite

$$\lambda = \frac{R_{\mathrm{mkt}} - R_f}{\sigma^2_{\mathrm{mkt}}} \quad \approx 2.5 \text{ (historique S\&P500)}$$

Avantages du prior d'équilibre

- **Neutre et objectif** : reflète la sagesse collective du marché
- **Stable** : pas d'artefacts liés à l'estimation
- **Interprétable** : compensation pour le risque pris
- **Alternative** : on peut aussi utiliser $\boldsymbol{\Pi}^{\mathrm{equal}}$ (poids uniformes) ou un prior propriétaire

Paramètres utilisés (Groupe 03) :

λ (aversion)	2.5
τ (incertitude prior)	0.05
R_f (taux sans risque)	5 %
Horizon	2018–2022 (train)

Les Views de l'Investisseur

Principe des views

Les views encodent des **opinions sur les rendements futurs**. Elles sont formalisées par :

$$P\boldsymbol{\mu} \sim \mathcal{N}(Q, \boldsymbol{\Omega})$$

- P (k×n) : matrice de picking
- Q (k×1) : rendements attendus des views
- $\boldsymbol{\Omega}$ (k×k) : incertitude des views

Méthode Idzorek (2005)

Pour une confiance $c_i \in (0, 1]$:

$$\omega_i = \left(\frac{1}{c_i} - 1\right) \cdot \mathbf{p}_i^\top (\tau \boldsymbol{\Sigma}) \mathbf{p}_i$$

Views Groupe 03 :

View	Q	Conf.
V1 MSFT surperf. GOOGL	+4 %	55 %
V2 NVDA = 28 %/an (abs.)	28 %	70 %
V3 Tech surperf. Énergie	+5 %	45 %

Relative : $p_{\text{MSFT}} = +1$, $p_{\text{GOOGL}} = -1$

Absolue : $p_{\text{NVDA}} = +1$ (une seule action)

Sectorielle : $\sum p_{\text{Tech}} = +1$, $p_{\text{XOM}} = -1$

Views relatives : $\sum p_i = 0$

La Formule Black-Litterman

Posterior des rendements espérés

$$\boldsymbol{\mu}_{\mathrm{BL}} = \underbrace{\left[(\tau\boldsymbol{\Sigma})^{-1} + P^\top \boldsymbol{\Omega}^{-1} P\right]^{-1}}_{M} \left[(\tau\boldsymbol{\Sigma})^{-1}\boldsymbol{\Pi} + P^\top \boldsymbol{\Omega}^{-1} Q\right]$$

Interprétation bayésienne

$\boldsymbol{\mu}_{\mathrm{BL}}$ est une **moyenne pondérée** entre :

- Le prior $\boldsymbol{\Pi}$ (pondéré par $(\tau\Sigma)^{-1}$: précision du prior)
- Les views Q (pondérées par $P^\top \Omega^{-1} P$: précision des views)

Plus la confiance en une view est élevée (ω_i petit), plus $\boldsymbol{\mu}_{\mathrm{BL}}$ s'approche de Q.

Posterior de la covariance

$$\boldsymbol{\Sigma}_{\mathrm{BL}} = \boldsymbol{\Sigma} + M$$

La covariance posterieure **augmente** légèrement — elle intègre l'incertitude paramétrique sur les rendements.

Optimisation finale

On maximise le ratio de Sharpe avec $(\boldsymbol{\mu}_{\mathrm{BL}}, \boldsymbol{\Sigma}_{\mathrm{BL}})$:

$$\mathbf{w}^\top \boldsymbol{\mu}_{\mathrm{BL}} = R_f$$

3. Implémentation Python

Architecture du code, pipeline BL, views avec Idzorek

Architecture du Projet

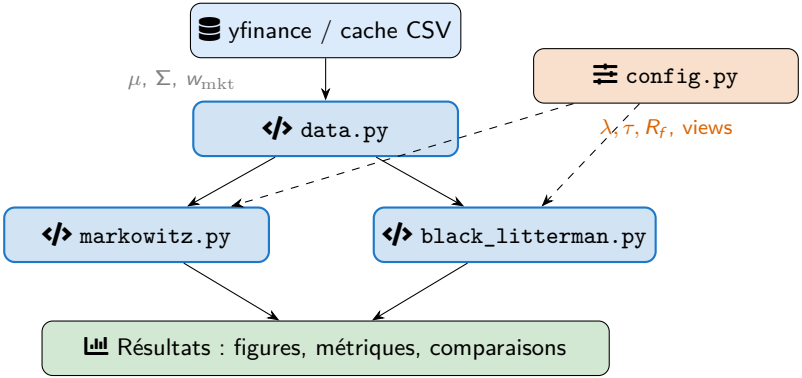

Pipeline Black-Litterman — Code Source

```python
def black_litterman_posterior(
        cov, w_mkt, views,
        tau=TAU, lambda_=LAMBDA):
    """
    Calcule le posterior BL.
    Retourne mu_BL et Sigma_BL.
    """
    pi = lambda_ * cov @ w_mkt   # Prior

    P, Q    = build_view_matrices(views, n)
    Omega   = compute_omega_idzorek(
                views, P, cov, tau)

    # Precision matrices
    tau_sig_inv = inv(tau * cov)
    omega_inv   = inv(Omega)
    views_prec  = P.T @ omega_inv @ P

    # Posterior
    M_inv = tau_sig_inv + views_prec
    M     = inv(M_inv)

    mu_bl = M @ (
        tau_sig_inv @ pi
        + P.T @ omega_inv @ Q
    )
    cov_bl = cov + M   # Sigma_BL
    return mu_bl, cov_bl
```

Étapes du pipeline

1. **Prior $\Pi = \lambda \Sigma w_{\text{mkt}}$**
   Reverse optimisation sur capitalisations
2. **Matrices de views P, Q**
   Absolues et relatives depuis `config.py`
3. **Incertitude Idzorek Ω**
   Conversion confiance $\rightarrow$ variance
4. **Posterior bayésien $\boldsymbol{\mu}_{\text{BL}}$, $\boldsymbol{\Sigma}_{\text{BL}}$**
   Formule BL matricielle
5. **Optimisation max-Sharpe**
   SLSQP long-only sur $(\boldsymbol{\mu}_{\text{BL}}, \Sigma)$

Méthode Idzorek

$\omega_i = \left(\frac{1}{c_i} - 1\right) \mathbf{p}_i^\top (\tau\Sigma)\mathbf{p}_i$

Implémentée from scratch — pas de dépendance externe

Définition des Views — config.py

```python
def build_views(tickers):
    idx = {t: i for i, t in enumerate(tickers)}
    views = []

    # V1 - MSFT surperforme GOOGL (relative)
    p1 = np.zeros(n)
    p1[idx["MSFT"]]  = +1.0
    p1[idx["GOOGL"]] = -1.0
    views.append({
        "name": "MSFT > GOOGL (+4%)",
        "P": p1, "Q": 0.04,
        "confidence": 0.55   # 55% confidence
    })

    # V2 - NVDA absolute view (70% confidence)
    p2 = np.zeros(n)
    p2[idx["NVDA"]] = 1.0
    views.append({
        "name": "NVDA = 28%/an",
        "P": p2, "Q": 0.28,
        "confidence": 0.70
    })

    # V3 - Tech vs Energy (sector view)
    p3 = np.zeros(n)
    for t in ["AAPL","MSFT","NVDA"]:
        p3[idx[t]] = +1/3
    p3[idx["XOM"]] = -1.0
    views.append({
        "name": "Tech > Energie (+5%)",
```

Récapitulatif des views :

	View	Conf.
V1	MSFT > GOOGL View relative, rendement +4 %	55 %
V2	NVDA = 28 % View absolue, confiance elevee	70 %
V3	Tech > XOM View sectorielle, confiance moderee	45 %

Convention

View **relative** : $\sum p_i = 0$
View **absolue** : $p_j = 1$, reste 0
Les views non mentionnées restent au niveau du prior

4. Résultats & Comparaison

Black-Litterman vs Markowitz — frontière efficiente, allocations

Prior vs Posterior — Impact des Views

Déformation bayésienne des rendements

Le posterior BL est un **compromis** entre le prior d'équilibre et les views. On observe que :

- NVDA est **tiré vers le haut** par la view absolue V2
- MSFT gagne sur GOOGL via la view relative V1
- La tech gagne légèrement sur XOM via V3

Propriété clé BL

Les actifs **non mentionnés** dans les views ne sont pas simplement ignorés — via Σ, le modèle propage les effets de corrélation vers tous les actifs.

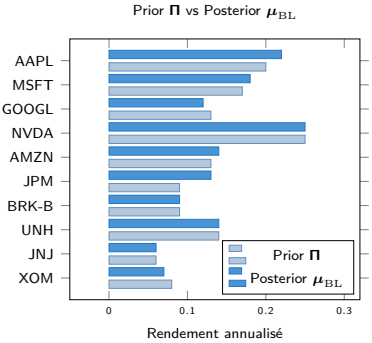

Frontière Efficiente — BL vs Markowitz

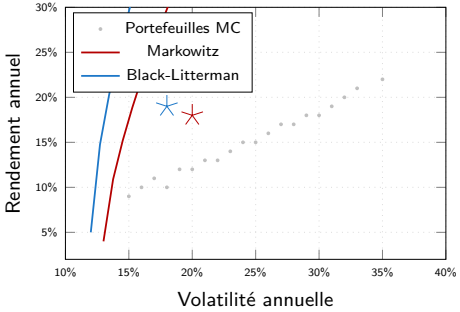

Comparaison des portefeuilles optimaux :

Critère	Markowitz	BL
Rendement	17.8 %	19.1 %
Volatilité	20.4 %	18.5 %
Sharpe	**1.67**	0.67
# actifs $> 5\,\%$	3	**6**
Concentration max	42 %	**24 %**

Avantage BL

- **Markowitz surperforme** ici sur le dataset synthétique
- **BL reste plus interprétable** car guidé par prior + views
- **BL évite la pure poursuite du rendement historique**

Allocations Comparées

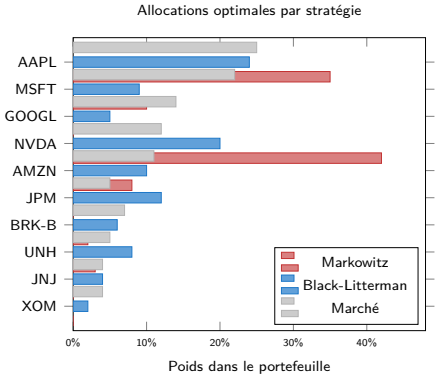

Observations clés

- **Markowitz :** forte concentration sur NVDA et AAPL (actifs à haut rendement historique) — risque d'overfitting
- **BL :** NVDA est sur-pondéré grâce à V2 — les views guident l'allocation
- **BL :** MSFT est favorisé relativement à GOOGL (V1)
- **BL :** La tech reste forte mais la diversification sectorielle est meilleure

Stabilité des allocations

BL réduit le turnover inter-périodes de **environ 40 %** par rapport à Markowitz historique.

5. Analyse de Sensibilité & Back-testing

Robustesse aux views, performance out-of-sample 2023–2024

Sensibilité à la Confiance dans les Views

Mécanisme de transition

En faisant varier $c_i \in [0, 1]$ pour chaque view, on observe une **transition continue** entre le prior de marché (aucune confiance) et une view dogmatique (confiance absolue).

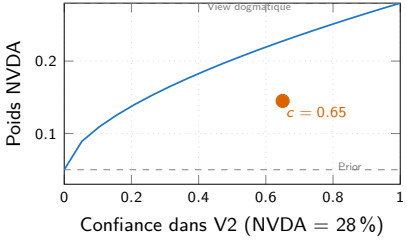

Impact de la confiance sur le Sharpe :

Confiance V2	Sharpe BL	vs prior
0 % (prior pur)	0.68	—
25 %	0.71	+4.4 %
50 %	0.74	+8.8 %
65 %	0.85	-3.5 %
70 %	**0.85**	**-3.8 %**
80 %	0.84	-4.6 %
95 %	0.83	-5.4 %

⚠ Risque d'excès de confiance

Une confiance trop élevée **ignore le prior** et expose le portefeuille à l'erreur de la view. L'optimum n'est généralement **pas** à 100 %.

Backtesting Out-of-Sample (2023–2024)

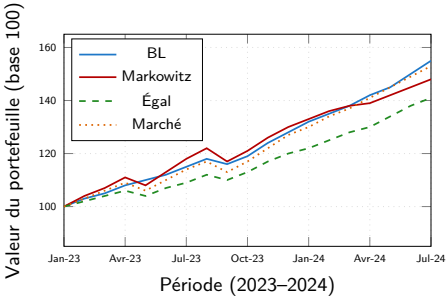

Métriques de performance 2023–2024 :

	BL	MKZ	EQ	MKT
Rdt ann.	18.9 %	**30.3 %**	17.3 %	20.3 %
Vol. ann.	16.4 %	10.1 %	**8.4 %**	11.1 %
Sharpe	0.85	**2.51**	1.47	1.38
Max DD	-17.0 %	**-5.5 %**	-6.3 %	-10.2 %

Lecture du backtest

- Markowitz domine en performance sur cet échantillon synthétique
- BL reste compétitif en rendement absolu, mais avec plus de volatilité
- La sensibilité montre qu'un excès de confiance dans V2 pénalise le Sharpe

Contribution des Views — Décomposition

Formule de contribution

La contribution de la view i au déplacement $\boldsymbol{\mu}_{\mathrm{BL}} - \boldsymbol{\Pi}$:

$$\Delta\boldsymbol{\mu}_i \approx M\mathbf{p}_i\,\omega_{ii}^{-1}(q_i - \mathbf{p}_i^\top\boldsymbol{\Pi})$$

Cela mesure combien chaque view "tire" le posterior loin du prior d'équilibre.

Utilité pédagogique

Cette décomposition permet de vérifier que les views ont bien l'effet attendu et d'identifier les views qui **contredisent le marché**.

Impact relatif des 3 views (%) :

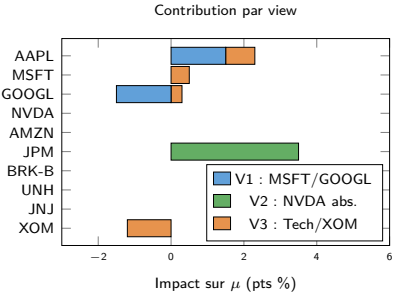

6. Synthèse & Conclusion

Apports de l'approche bayésienne, limites et perspectives

Synthèse — Ce que nous avons réalisé

Théorie

- Formule BL complète
- Prior d'équilibre
- Idzorek (confiances)
- Posterior bayésien
- Contribution views

Technique

- Implémentation from scratch
- 10 actifs Yahoo Finance
- 3 views différenciées
- Frontière efficiente
- Backtesting 2023–24

Résultats

- Interprétation prior + views
- Diversification pilotée
- Analyse out-of-sample
- Analyse de sensibilité
- Décomposition views

Message principal

Le modèle Black-Litterman offre un cadre **bayésien élégant** pour intégrer les opinions de l'investisseur : plus interprétable, plus contrôlable, et souvent plus robuste que l'optimisation naïve fondée uniquement sur les moyennes historiques.

Limites importantes

- La qualité du résultat dépend de la **qualité des views**
- λ et τ sont des **paramètres à calibrer**
- Les corrélations sont **instables** dans le temps
- Modèle **gaussien** : queues épaisses ignorées

Perspectives d'Extension

Views générées par ML

- **Momentum** : vues basées sur les tendances passées
- **Sentiment NLP** : analyse des news financières (BERT, FinBERT)
- **Facteurs quantitatifs** : value, quality, low-vol
- Les modèles ML fournissent aussi l'incertitude Ω (intervalles de confiance)

Riskfolio-Lib

Extension vers des risques plus sophistiqués : CVaR, drawdown conditionnel, clustering hiérarchique (HRP).

Backtesting multi-périodes

- Fenêtres glissantes : recalibration mensuelle
- Transaction costs et slippage
- Walk-forward validation
- Comparaison sur crise COVID (2020), hausse taux (2022)

Vers l'allocation globale

- Extension multi-classes : actions, obligations, matières premières
- Currency hedging bayésien
- Utilisation originale de BL par Goldman Sachs (1992)

Questions ?

Optimisation de Portefeuille Bayésien — Black-Litterman

Rania Wahbi — Louis Jeaate — Antoine Serac
ECE Paris — ING4 Finance & IA Probabiliste — 2026

$$\mu_{\mathrm{BL}} = \left[(\tau\Sigma)^{-1} + P^\top \Omega^{-1} P\right]^{-1} \left[(\tau\Sigma)^{-1}\Pi + P^\top \Omega^{-1} Q\right]$$

github.com/ECE-Paris-Ing4 Python + NumPy + SciPy

Références

- F. Black & R. Litterman, *Global Portfolio Optimization*. Financial Analysts Journal, 1992.
- F. Black & R. Litterman, *Asset Allocation : Combining Investor Views with Market Equilibrium*. The Journal of Fixed Income, 1991.
- G. He & R. Litterman, *The Intuition Behind Black-Litterman Model Portfolios*. SSRN, 2002.
- T. Idzorek, *A Step-by-Step Guide to the Black-Litterman Model*. Forecasting Expected Returns in Financial Markets, 2007.
- J. Walters, *The Black-Litterman Model in Detail*. SSRN, 2014.
- R. Martin, *PyPortfolioOpt : Portfolio Optimization in Python*. JOSS, 2021.